No es permet l'ús de:

- **Assistents automàtics de codi**
- **Telèfons mòbils**
- **Qualsevol eina externa que faci el treball de manera automàtica**
- **Accés a Internet llevat de API oficial de les llibreries**

Qualsevol infracció implicarà un 0 directe.

Pràctica 3 — Preprocessat i Naive Bayes

L'objectiu d'aquesta pràctica és treballar les fases inicials d'un procés de data mining, especialment el preprocessat de dades, i aplicar un model senzill de classificació basat en els conceptes de probabilitat vistos a classe.

En les xarxes bayesianes, les dependències entre variables es representen mitjançant un graf dirigit, on cada variable pot dependre d'altres. El model Naive Bayes es pot entendre com un cas simplificat d'una xarxa bayesiana on:

- Existeix una variable objectiu Y
- Totes les variables d'entrada $X_1, X_2, ..., X_n$ depenen únicament de Y
- Les variables d'entrada són independents entre si donada la classe

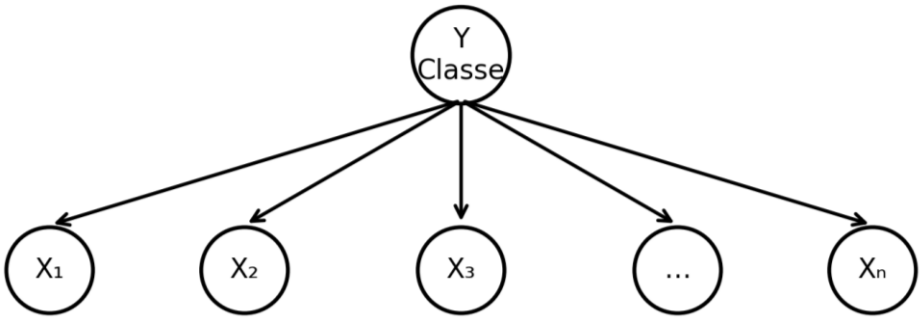

Estructura d'un classificador Naive Bayes

Aquesta estructura implica que el model calcula la probabilitat de la classe donats els atributs:

$$P(Y \mid X_1, X_2, ..., X_n)$$

i assumeix que:

$$P(X_1, ..., X_n \mid Y) = \prod_i P(X_i \mid Y)$$

En un dataset, això correspon a:

$(X_1, X_2, \ldots., X_n)$ → columnes d'entrada (atributs)

Y → columna de sortida (classe a predir)

Aquesta simplificació permet construir models senzills i eficients, tot i que no sempre reflecteix les dependències reals entre variables (i per això s'anomena "Naive" Bayes).

Dataset

Es disposa d'un conjunt de dades amb diversos atributs i una variable objectiu. Aquestes dades poden contenir problemes habituals (valors mancants, formats no adequats, etc.), que caldrà tractar abans d'aplicar cap model. El conjunt de dades conté informació sobre personatges de l'univers Star Wars. Cada instància correspon a un personatge amb diferents atributs físics i descriptius.

L'objectiu és utilitzar aquestes dades per construir un model de classificació basat en Naive Bayes.

Variables d'entrada ($X_1, X_2, ..., X_n$)

Cada personatge està descrit mitjançant els següents atributs:

- **height**: altura del personatge
- **hair_color**: color de cabells
- **skin_color**: color de pell
- **eye_color**: color d'ulls
- **birth_year**: any de naixement
- **sex**: sexe del personatge
- **gender**: gènere del personatge
- **species**: espècie del personatge

Aquestes variables corresponen a:
$X_1, X_2, ..., X_n$ en el model Naive Bayes

Variable objectiu (Y)

El que volem predir:

- **homeworld**: planeta d'origen

Tasques a realitzar:

1. **Càrrega del dataset**
   Carrega el dataset de Star Wars com un dataframe de pandas.

2. **Anàlisi inicial del dataset**
   Inspecciona el dataset i respon:

   - Quantes instàncies conté?
   - Quantes variables té?

3. **Selecció de variables**
   Suposa que volem construir un model que predigui el planeta d'origen (homeworld).

   - Creus que totes les variables són rellevants?
   - Quines variables consideres importants?
   - Quines eliminaries?

   Elimina les variables que consideris no rellevants i justifica la decisió.

4. **Separació de variables (X i Y)**
   En data mining es distingeix entre variables predictores (X) i variable objectiu (Y)

   Separa el dataset en:

   - conjunt de variables d'entrada (X)
   - variable objectiu (Y)

5. **Train / Test split**
   En data mining, el model s'entrena amb un conjunt de dades i s'avalua amb dades noves.

   - Divideix el dataset en conjunt d'entrenament i de test
   - Quin percentatge utilitza per defecte la llibreria?
   - Modifica'l perquè el conjunt de test sigui del 30%

6. **Construcció dels models**
   Construeix i entrena els següents models (de scikit-learn) utilitzant el conjunt d'entrenament:

   - Un model DummyClassifier amb estratègia "most_frequent"
   - Un model Gaussian Naive Bayes

7. **Avaluació dels models**
   Compara els resultats dels dos models:

   - Calcula les mètriques de rendiment
   - Mostra les matrius de confusió
   - Analitza els resultats obtinguts

   Explica per què els resultats són baixos en aquest dataset.